

# Relatório

## Projeto 1 - MLP

Profª Roseli Aparecida Francelin Romero  
Monitor PAE Caetano Ranieri

Matheus Bernardes dos Santos - 9277979  
Rodrigo Anes Sena de Araújo - 9763064

## Resumo

Este projeto tem como objetivo a implementação de uma Rede MLP (Multi Layer Perceptron) e a partir deste, fazer a realização de testes em duas bases de dados: wine.data e default\_features\_1059\_tracks.txt.

Modelos diferentes de MLP serão utilizadas a fim de comparação de resultados e desempenhos. Apresentando uma variação na quantidade de camadas ocultas, na quantidade de ciclos, velocidade de aprendizado e momentum, mostraremos diversos resultados obtidos.

Também será abordado um problema de **classificação**, onde obteremos a acurácia para o conjunto de treinamento e teste e, o problema de **aproximação**, onde teremos o erro quadrático médio obtido.

Para fazer o uso da rede MLP desenvolvida é preciso colocar as bases de dados wine e track de música no /content/ do Colab Notebook e, a partir disso, fazer a execução das células dispostas.

## Arquitetura MLP

A partir de um modelo genérico de uma MLP (Figura 1), ajustamos conforme necessário a arquitetura para atender ao projeto.




Figura 1: modelo genérico de uma MLP

Em primeira instância temos uma camada de input com  $N$  neurônios, uma camada oculta com  $\log_2 N$  neurônios e uma camada de saída com  $N$  neurônios.

Após a alteração, nosso modelo apresenta uma camada de input com  $N$  neurônios, duas camadas ocultas com  $\log_2 N$  neurônios cada e uma camada de saída com  $N$  neurônios.

Vale ressaltar que nas duas arquiteturas foram alterados o momentum, número de ciclos utilizados e a velocidade de aprendizado.

Nº camadas ocultas	Nº ciclos	Velocidade apr	Momentum	proporção treino/teste
1	100	0.5	0.5	0.2
	50	0.3	0.4	0.4
2	20	0.7	0.3	0.6
	10	0.1	0.6	0.8

Variação de estrutura da MLP

## Resultados

### Problema de classificação

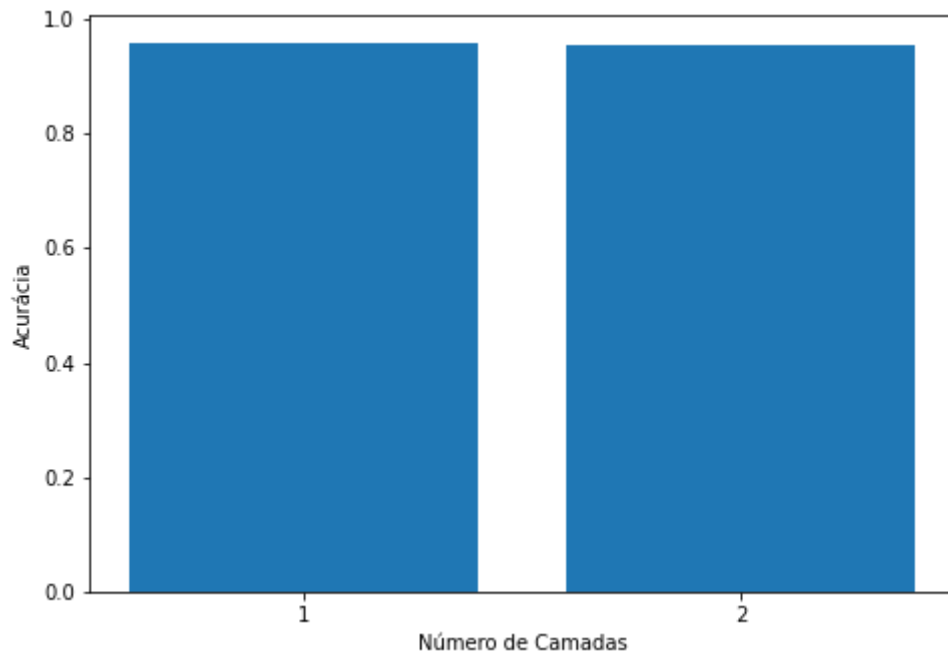
Para o problema de classificação, foi utilizado o conjunto de dados wine, que contém a classificação de três tipos de vinho, por meio da análise de 13 atributos, e uma coluna inicial com a classificação. A rede foi treinada seguindo uma variação da arquitetura MLP como mostrada na tabela anterior.

Estudamos o impacto da variação isolada de cada termo da MLP e exibimos os seguintes resultados:

- Variação do número de camadas intermediárias:

Acurácia em 1 Camada: 0.96

Acurácia em 2 Camadas: 0.9542857142857144



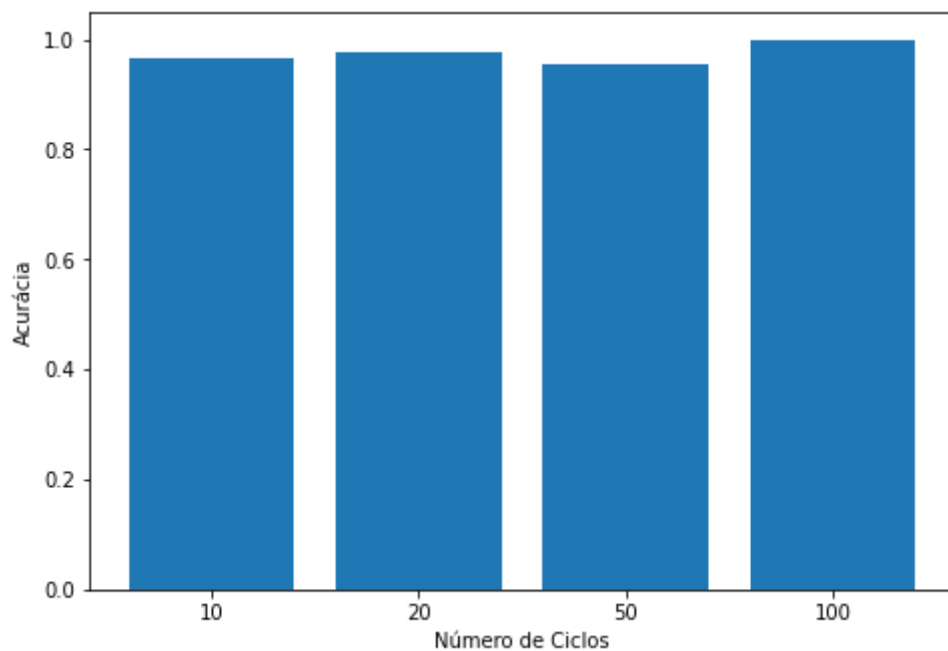
- Variação do número de ciclos(epoch):

Acurácia em 10 Ciclos : 0.9657142857142859

Acurácia em 20 Ciclos : 0.9771428571428572

Acurácia em 50 Ciclos : 0.9542857142857143

Acurácia em 100 Ciclos : 1.0




- Variação da velocidade de aprendizado(eta):

Acurácia com eta = 0.1 : 0.9428571428571428

Acurácia com eta = 0.3 : 0.9828571428571429

Acurácia com eta = 0.5 : 0.9657142857142856

Acurácia com eta = 0.7 : 0.9714285714285715




- Variação do Momentum:

Acurácia com Momentum = 0.3 : 0.9771428571428572

Acurácia com Momentum = 0.4 : 0.9485714285714286

Acurácia com Momentum = 0.5 : 0.96

Acurácia com Momentum = 0.6 : 0.9485714285714286




- Variação da proporção do conjunto treino/teste:

Acurácia com proporção = 0.2 : 0.9771428571428572

Acurácia com proporção = 0.4 : 0.9830985915492958

Acurácia com proporção = 0.6 : 0.9716981132075471

Acurácia com proporção = 0.8 : 0.9267605633802816



## Problema de aproximação

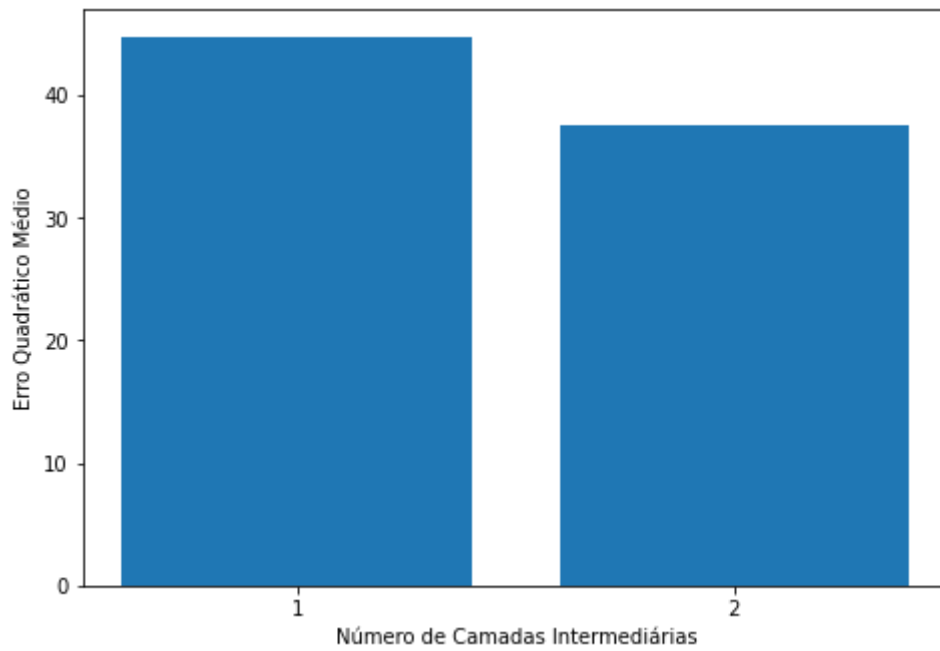
Para o problema de aproximação/regressão foi utilizado um conjunto de dados "Geographical Original of Music", contendo 1059 tracks de músicas e sua localização geográfica dada por latitude e longitude. A base possui 68 atributos e suas duas últimas colunas contém a latitude e longitude, respectivamente.

A rede foi treinada seguindo uma variação da arquitetura MLP como mostrada na tabela anterior. Estudamos o impacto da variação isolada de cada termo da MLP e exibimos os seguintes resultados:

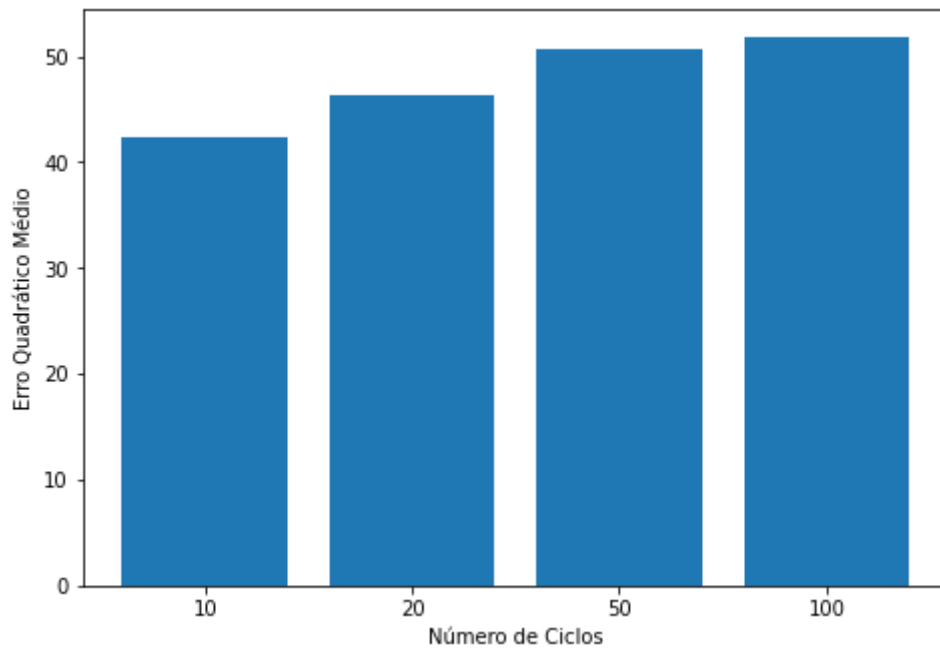
- Variação do número de camadas intermediárias:

Erro quadrático médio em 1 Camada: 44.831108944215

Erro quadrático médio em 2 Camadas : 37.63251584244816




- Variação do número de ciclos(epoch):
  - Erro quadrático médio em 10 Ciclos : 42.31655672153049
  - Erro quadrático médio em 20 Ciclos : 46.24289247078751
  - Erro quadrático médio em 50 Ciclos : 50.59857974078491
  - Erro quadrático médio em 100 Ciclos : 51.89033455604108



- Variação da velocidade de aprendizado(eta):

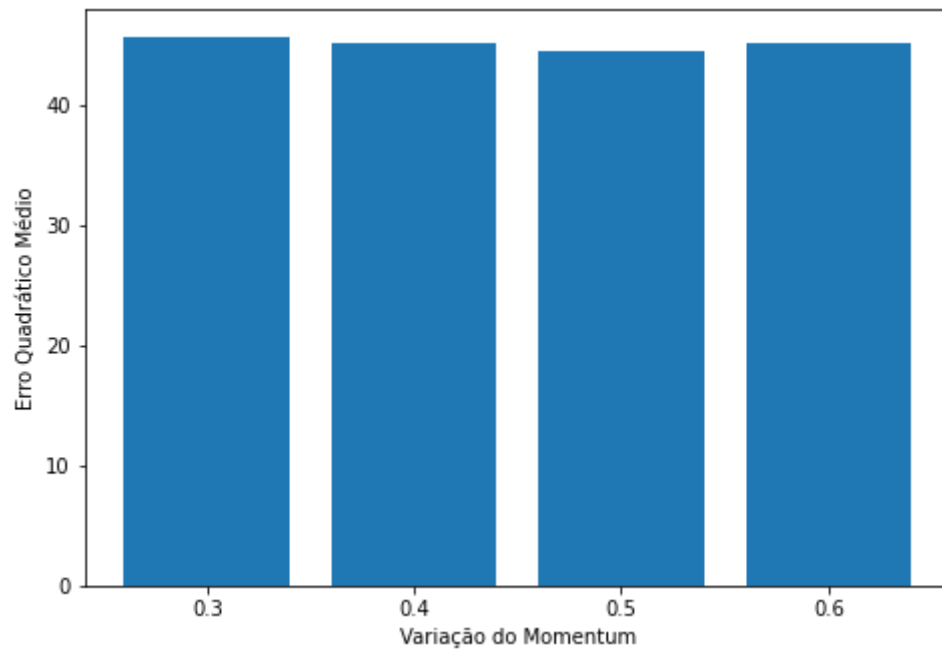
Erro quadrático médio com eta = 0.1 : 44.48724622296768  
 Erro quadrático médio com eta = 0.3 : 44.43770676948101  
 Erro quadrático médio com eta = 0.5 : 47.41494583526186  
 Erro quadrático médio com eta = 0.7 : 45.028901020563715



- Variação do Momentum:

Erro quadrático médio com momentum = 0.3 : 45.76307720342224  
 Erro quadrático médio com momentum = 0.4 : 45.12505346708609  
 Erro quadrático médio com momentum = 0.5 : 44.53086451587617  
 Erro quadrático médio com momentum = 0.6 : 45.10844184891774






- Variação da proporção do conjunto treino/teste:

Erro quadrático médio com proporção = 0.2 : 44.967010965294484

Erro quadrático médio com proporção = 0.4 : 46.5268284446918

Erro quadrático médio com proporção = 0.6 : 47.70891327934302

Erro quadrático médio com proporção = 0.8 : 47.00280550942885



Bases de dados disponíveis em:

<https://archive.ics.uci.edu/ml/datasets/Wine>

<https://archive.ics.uci.edu/ml/datasets/Geographical+Original+of+Music>